PGR - GPU, Rendering pipeline, OpenGL

Tomáš Milet

Brno University of Technology, Faculty of Information Technology
Božetěchova 1/2. 612 66 Brno - Královo Pole
imilet@fit.vutbr.cz

14. října 2022

Overview of GPU architecture / Přehled architektury GPU

GPU over the years / GPU architektura v průběhu let

- At first, everything was fixed in HW / just 2D acceleration.
- 3D acceleration next, specialized HW.
- Next, partially programable pipeline.
- Now, large number of cores for general computation, (2D emulated).
- Nejprve pouze 2D akcelerace
- Poté 3D akcelerace, specializovaný HW
- Dál částečně programovatelná pipeline
- Nyní velké množství výpočetních jednotek pro obecné výpočty (2D akcelerace emulovaná pomocí 3D)

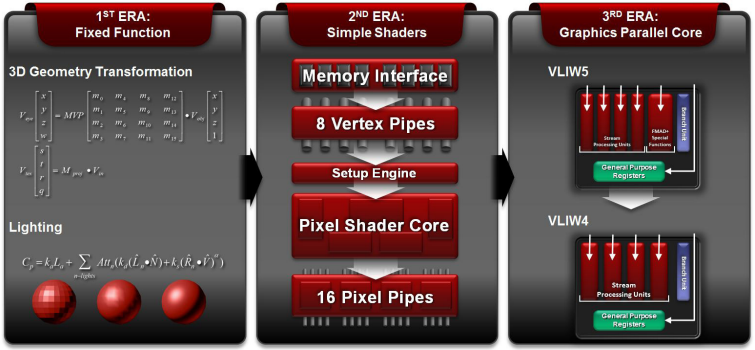

GPU vs CPU

- CPU - small number of very fast computing units.
- Large caches, large control, out-of-order instruction execution, ...
- GPU - large number of not that fast computing units, simpler units.
- Smaller caches, small control, more transistors allocated for computation, ...
- GPU - data parallel, semi tast parallel
- CPU - tast parallel, semi data parallel
- CPU - málo, velmi výkonných výpočetních jednotek
- Velká keš, velké řízení, vykonávání instrukcí mimo pořadí, ...
- GPU - velké množství méně výkonných, jednodušších výpočetních jednotek
- Malé keše, malé řízení, víc tranzistorů pro výpočty, ...
- GPU - data parallel, náznak task parallel
- CPU - tast parallel

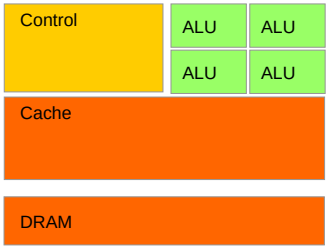

CPU

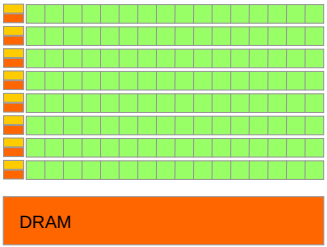

GPU

GPU vs CPU

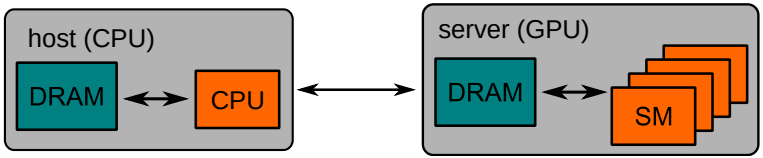

- GPU is composed from multi-processors and device memory.
- Nvidia - streaming multi processor (SM).
- AMD - compute unit (CU).
- Multi-processor is composed of SIMD units and various kings of memory.
- Computation executed on one multi-processor is independed from computation on other multi-processors.
- SIMD cores are commony reffered as shader unit (AMD Radeon HD7970M 20xCU, 64 shader unit per CU, = 1280 shader unit).

- Grafická karta je složena z několika multiprocesorů a grafické paměti.
- Nvidia - streaming multi processor (SM).
- AMD - compute unit (CU).
- Tento multiprocessor je dále složen z velkého množství jader a různých druhů pamětí.
- Akce, která beží na jednom multiprocesoru je nezávislá na akci, která běží na jiném multiprocesoru.
- Jádra bývají označována jako shader unit (AMD Radeon HD7970M 20xCU, 64 shader unit na CU, = 1280 shader unit).


PCI Express 3.0 Host Interface
GigaThread Engine
GPC
Raster Engine
TPC
PolyMorph Engine
SM
Memory Controller
L2 Cache
GPC
Raster Engine
TPC
PolyMorph Engine
SM
Memory Controller
Memory Controller
Memory Controller
Memory Controller
Memory Controller
Memory Controller
Memory Controller
SM
PolyMorph Engine
TPC
Raster Engine
GPC
SM
PolyMorph Engine
TPC
Raster Engine
GPC

AMD FuryX/fiji

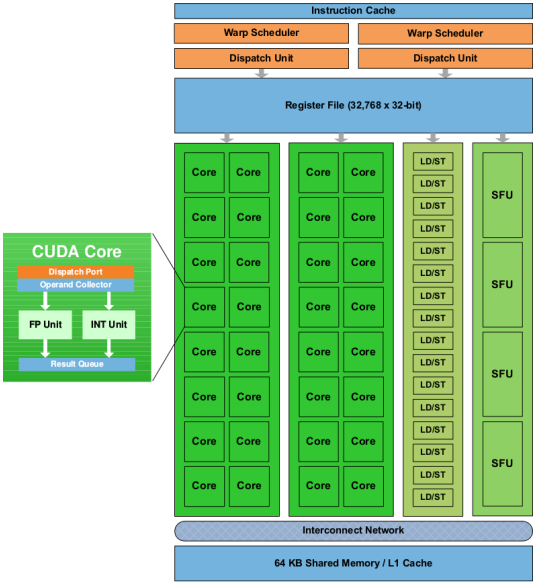
Instruction Cache
Warp Scheduler
Warp Scheduler
Dispatch Unit
Dispatch Unit
Register File (32,768 x 32-bit)
Core
LD/ST
SFU
CUDA Core
Dispatch Port
Operand Collector
FP Unit
INT Unit
Result Queue
Interconnect Network
64 KB Shared Memory / L1 Cache

NVIDIA - 1080 SMX

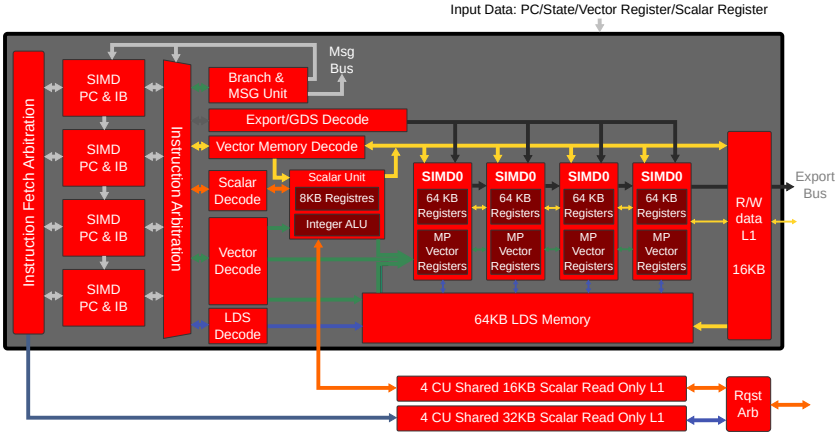
Input Data: PC/State/Vector Register/Scalar Register
Instruction Fetch Arbitration
SIMD PC & IB
SIMD PC & IB
SIMD PC & IB
SIMD PC & IB
Instruction Arbitration
Msg Bus
Branch & MSG Unit
Export/GDS Decode
Vector Memory Decode
Scalar Decode
Scalar Unit
8KB Registres
Integer ALU
Vector Decode
LDS Decode
SIMD0
64 KB Registers
MP Vector Registers
SIMD0
64 KB Registers
MP Vector Registers
SIMD0
64 KB Registers
MP Vector Registers
SIMD0
64 KB Registers
MP Vector Registers
R/W data L1
16KB
Export Bus
64KB LDS Memory
4 CU Shared 16KB Scalar Read Only L1
4 CU Shared 32KB Scalar Read Only L1
Rqst Arb

Non programable parts of GPU / Hardwarové části

- Today's GPUs are highly programable.
- Few parts remain fixed for configurable.
- Rasterization - converting vector primitives to fragments.
- Tessellation - splitting polygons into many sub-polygons.
- Texture units - filtering, wraping, compression, ...
- Per-fragment-operation, depth buffer, stencil buffer, ...
- Ray-tracing, ...
- And more
- Some parts are inaccessible from some APIs (CUDA cannot use rasterization).

- Dnešní GPU jsou značně programovatelné
- Některé části stále zůstávají hardwarově zadrátované
- Rasterizace - převod trojúhelníků na fragmenty
- Tessellace - rozřezání polygonů na mnoho podpolygonů
- Texturovací jednoty - filtrování, opakování na okrajích, ...
- Depth buffer, Stencil buffer, ...
- A další
- Ke většině lze přistoupit pouze z některých API (OpenGL, Vulkan, DirectX)

Memory Hierarchy / Paměťová hierarchie

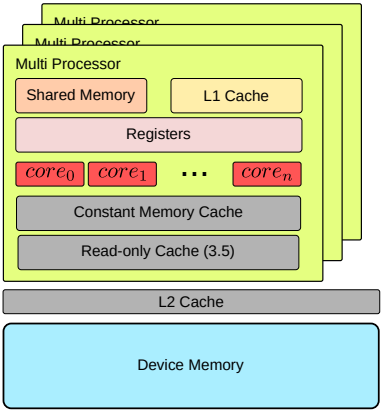

- Different memory types with different size and speed.
- General rule: closer to core, faster, smaller memory.
- Registers are fastest (Ada contains 256KB of registers per SM).
- Shared/Local memory is used for thread communication.
- Device memory/global memory is cached using L2 cache. Large, big latency (100s of clocs).

- Spousta různých pamětí s různou velikostí a rychlostí.
- Obecně platí, čím blíže k jádru, tím rychlejší a tím menší.
- Registry jsou nejrychlejší (na Ada je 256KB registrů na SM).
- Sdílená paměť slouží pro komunikaci mezi vlákny.
- Device memory (global memory) je velká (16GB i více), ale pomalá paměť.

Thread Hierarchy / Vláknová hierarchie

- Thread is kernel instantion with unique index.
- Kernel/Shader is program composed of instruction.
- User launches 1000s of threads - Dispatch.
- Dispatch is divided into work-groups. Whole work-group runs on one SM.
- WG are further divided into Warps/Wavefronts (32/64 threads sub-groups).
- Warps/Wavefronts are executed on SIMD unit. (One warp per one SIMD).
- Threads in WG can be synchronized and can use shader memory.
- WG are 1D, 2D, 3D (dictates thread ordering and indices).
- Terminology differs (OpenCL, Cuda, Compute Shader, ...).

- Na GPU pouštíme instance kernelů - vlákna.
- Kernel je program složený z instrukcí (podobně jako shader) a běží ve vláknu.
- Instrukce v kernelu jsou spouštěny v mnoha instancích na jádrech SM.
- Vlákna (thread, invocation, work-item) jsou seskupovány do pracovních skupin (work-group).
- Vlákna v pracovních skupinách můžou být na sobě závislá.
- Skupiny můžou být 1D, 2D, 3D (určuje pořadí vláken a jejich index).
- Mnoho work-group tvoří dispatch (taky může být 1D, 2D, 3D).
- Terminologie se liší (OpenCL, Cuda, Compute Shader, ...).

OpenGL Compute Programming Model and Compute Memory Hierarchy

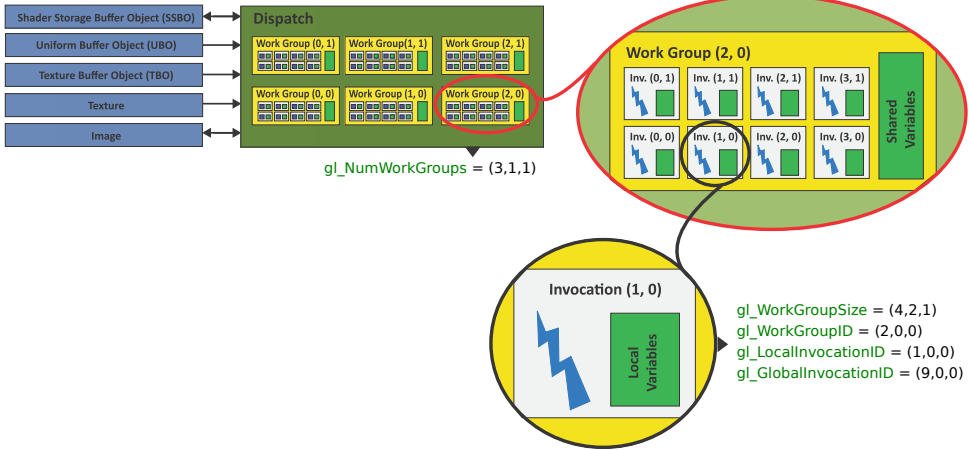

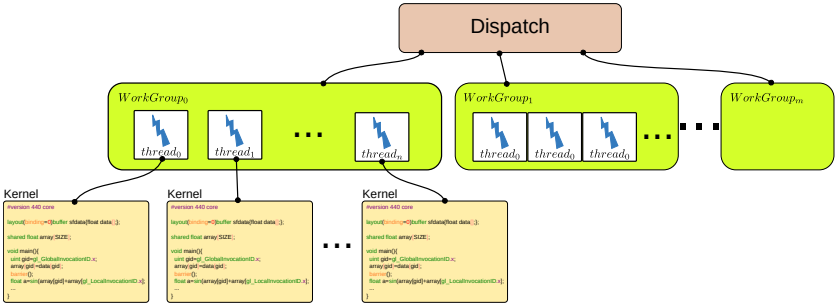

- Threads are grouped to work-groups.
- Work-group can be 1D, 2D, 3D.
- WG are grouped into dispatch.
- Dsipatch can also be 1D, 2D, 3D.
- One SM can lauch multiple work-groups, if there is enough resourses (registers, shader memory).
- Vlákna jsou seskupena do skupin work-group.
- Work-group může být 1D, 2D, 3D.
- Work-groupy jsou seskupeny do dispatch.
- Dispatch může být také 1D, 2D, 3D.
- Na jeden SM se může pustit vícero Work-group, pokud na to vystačí zdroje (registry, sdílená paměť)!

Model representation / Reprezentace modelu

- Main goal of the GPU is to conver 3D vector graphics to raster graphics (framebuffer)
- Hlavním úkolem grafické karty je převod 3D vektorové grafiky na rastrový obrázek (framebuffer).

- Boundary representation (B-rep) - vector graphics.
- Povrchová reprezentace - vektorová data.

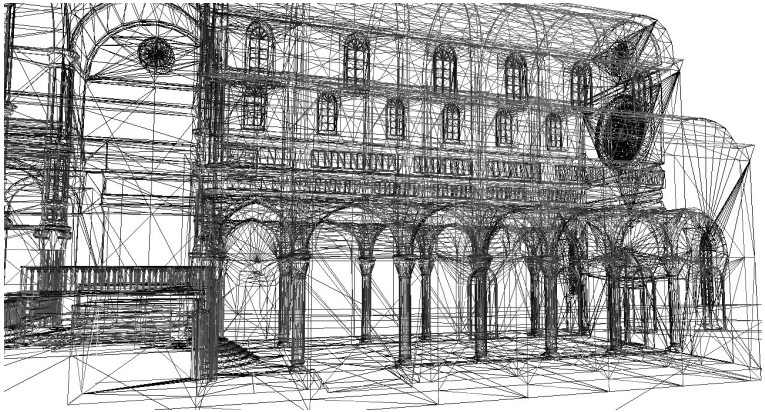

- 3D Vector graphics is not just points, lines and polygons.
- A GPU renders geometry based on vertices.
- A vertex is not just point in 3D space.
- A vertex is structure of user specific data.
- Jeden Vertex může obsahovat několik různých atributů (pozice, barva, čas, hmotnost, texturovací koordináty,...)
- Několik Vertexů tvoří jedno primitivum - bod, úsečka, trojúhelník,...
- 3D Vektorová grafika nejsou jen body, hrany a polygony.
- GPU kreslí geometrii založenou na vertexech.
- Vertex není jen bod v 3D prostoru.
- Vertex je struktura uživatelských dat.
- Jeden Vertex může obsahovat několik různých atributů (pozice, barva, čas, hmotnost, texturovací koordináty,...)
- Několik Vertexů tvoří jedno primitivum - bod, úsečka, trojúhelník,...

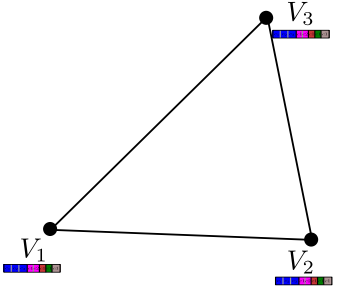

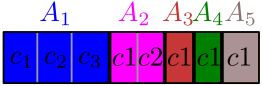

Example: 1 vertex contains 5 attributes.
1. attribute is composed of 3 elements.

Vertex Buffer Object (VBO)
1 or more VBO contains list of vertices.

Geometry terminology / Geometrická terminologie

The scene is usually composed using:

- A scene graph - user friendly, hierarchical structure of the scene.
- A model - one object of the scene. Can be instanced.
- A mesh - one piece of model. 1 material, 1 kind of geometry.
- A primitive - geometric piece, 2 categories: base primitives (point, line, triangle) and primimitive.
- A vertex - structure of user specific vertex attributes (data).
- A vertex attribute - 1-4D vector of floats or integers.
- A vertex buffer - memory containing vertices.
- A element/index buffer - memory containing indices to vertices.

Scéna je obvykle složena z:

- Graf scény - uživatelsky přívětivá hierarchická struktura scény.
- Model - jeden objekt scény, který je možné instanciovat.
- Mesh - jeden kousek modelu, obvykle má jen jeden materiál a jeden typ geometrie.
- Primitivum - geometrický kousek, dvě kategorie: základní primitiva (bod, úsečka, trojúhelník) a primitiva.
- Vertex - struktura uživatelských vertex atributů (data).
- Vertex atribut - 1-4 dimenzionální vektor floatů nebo integerů.
- Vertex Buffer - paměť obsahující vrcholy.
- Index/Element buffer - paměť obsahující indexy na vrcholy.

- The base primitive is subset of all primitives. There are only 3 types - triangles, lines, points. There is specialized rasterization hardware for each type. More complex primitives are composed of these base primitives.
- Základní primitiva tvoří podmnožinu všech primitiv. Jsou jen tři typy (trojúhelník, úsečka, bod). Pro každý je rasterizační hardware. Složitější primitiva jsou z nich složena.

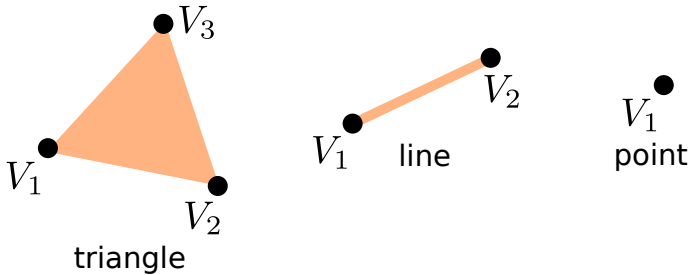

Common Primitives / Běžná primitiva

- Base primitives together with these primitives form commonly used primitives. Main purpose is to reduce memory footprint and processing time.
- Kromě základních primitiv se ještě běžně používají tato primitiva. Hlavním účelem je ušetřit paměť a čas zpracování.

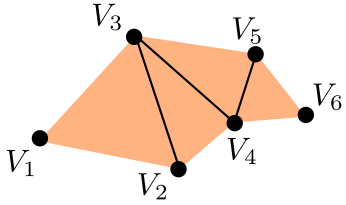

triangle strip

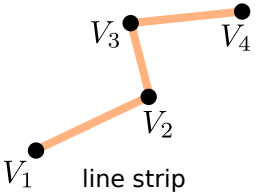

line strip

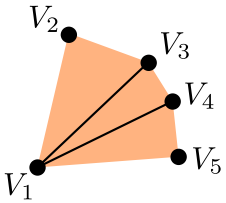

triangle fan

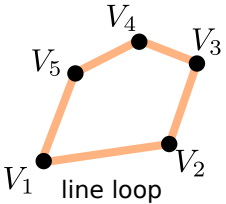

line loop

Primitives with adjacency / Primitiva se sousedností

- There are also primitives with adjacency (mainly for geometry shader).
- Existují také primitiva se sousedností (hlavně pro geometry shader).

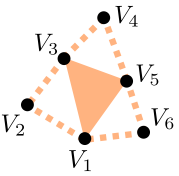

triangle adjacency

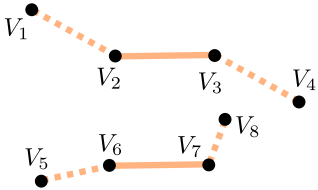

line adjacency

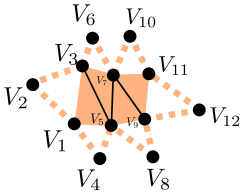

triangle strip adjacency

Zobrazovací řetězec

- GPU je rozděleno na paměť a vykreslovací řetězec.

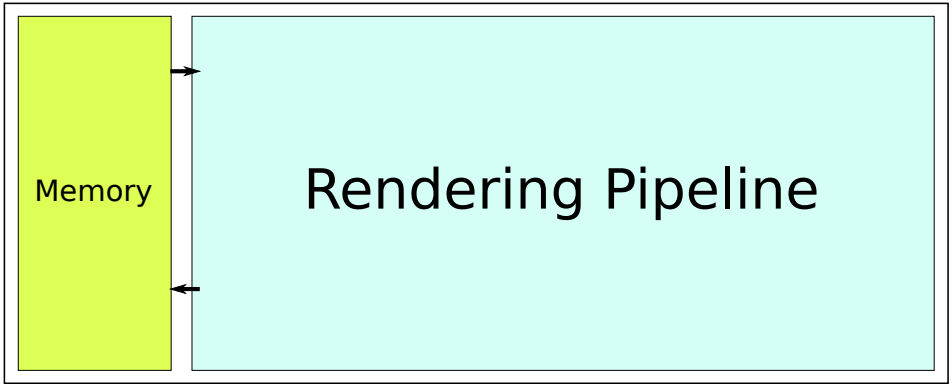

- Zobrazovací řetěžec je rozdělen na 2 části - vektorovou a rastrovou.
- Dělícím prvkem je rasterizace.

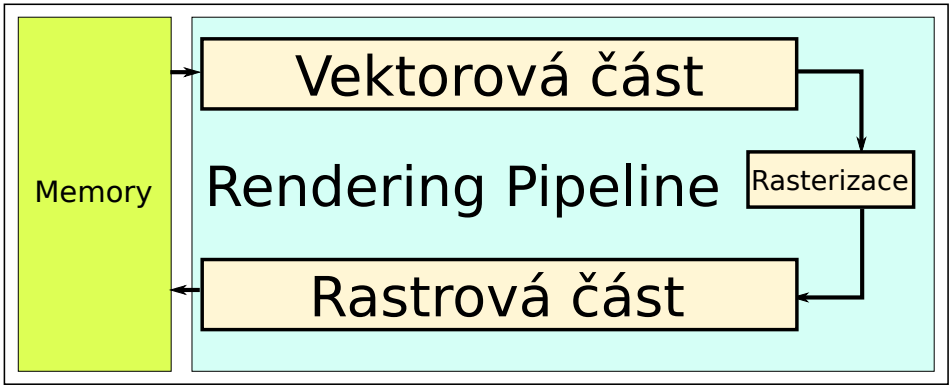

Vektorová část zobrazovacího řetězce

- Vektorová část řetězce je složena z mnoha bloků.
- Některé bloky jsou programovatelné a některé vynechatelné.

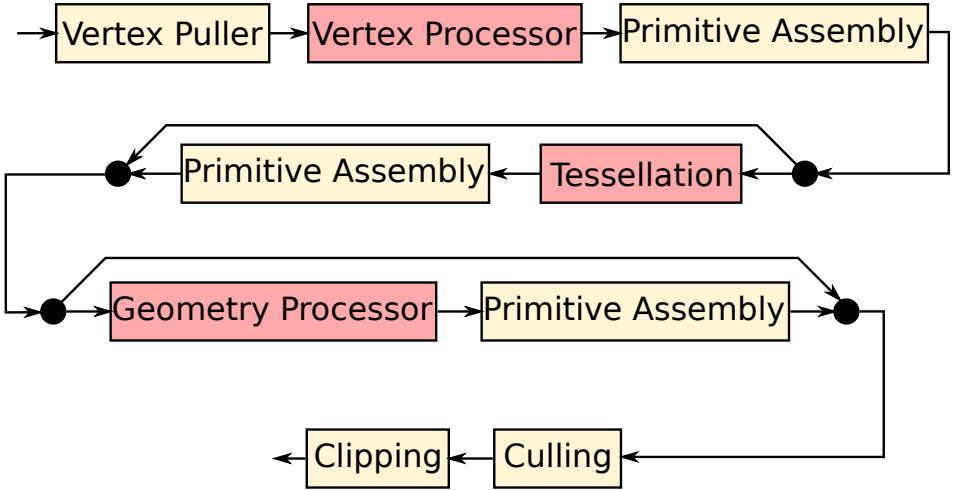

Zlednodušená Vektorová část

- Pokud vynecháme volitelné bloky, zůstane zjednodušená vektorová část řetězce.

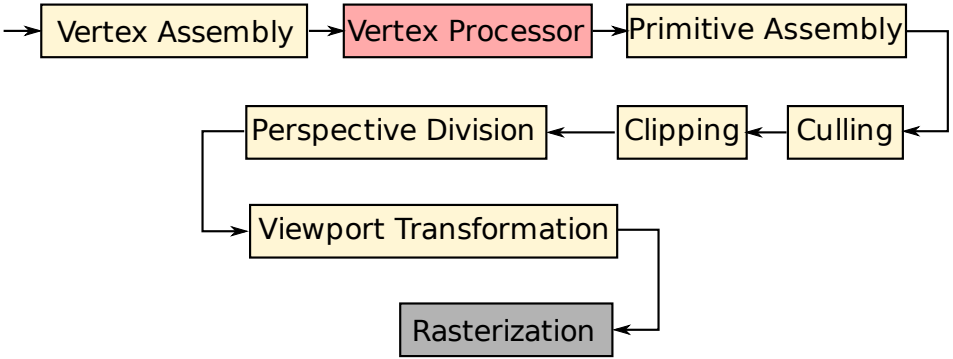

Vertex Assembly, vertex processor, primitive assembly

- Vertex Assembly sestavuje vrcholy
- Vertex processor transformuje vrcholy
- Primitive assembly sestavuje primitiva.

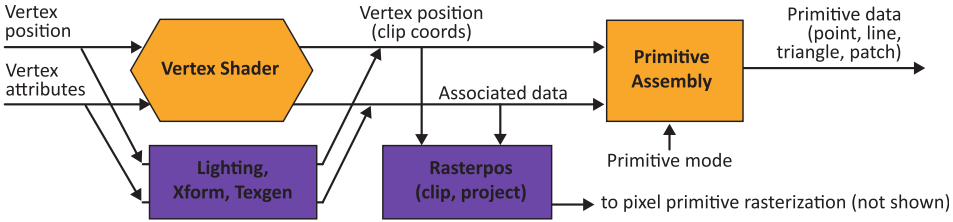

Vertex, Vertex Assembly

- Vertex je kolekce atributů
- Vertex Assembly jednotka se stará o sestavování vrcholů z bufferů.

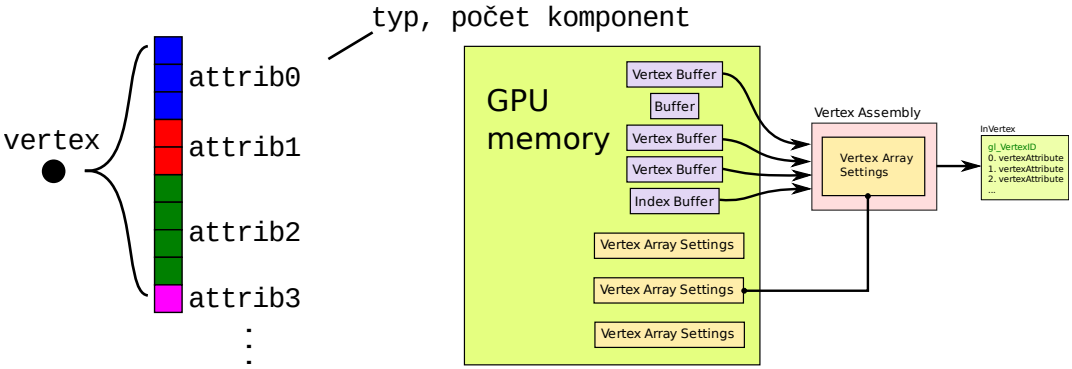

Vertex Assembly - indexované kreslení

- Vertex Assembly může využít indexování
- Vertex Cache

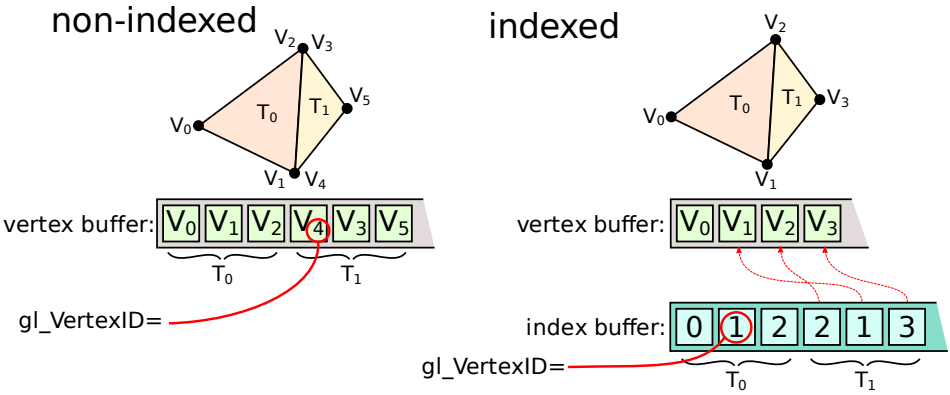

- Ve Vertex Processoru běží vertex shader.
- Vertex Shader je uživatelem specifikovaný program.
- Cílem je transformovat vstupní vrchol na výstupní vrchol.

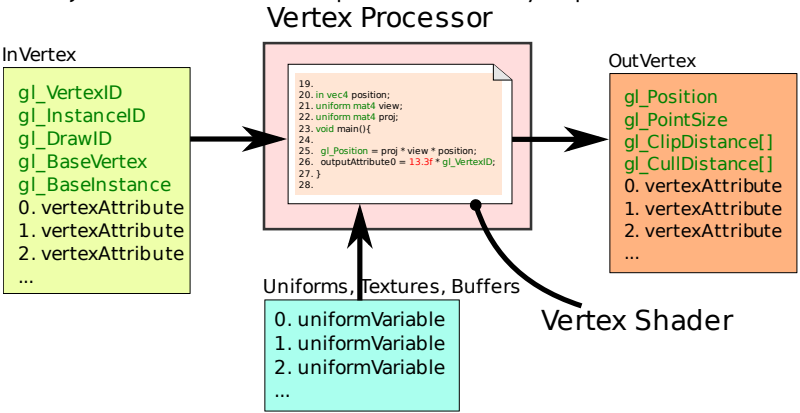

- Primitive Assembly jednotka sestavuje primitiva.
- Cílem je podle nastavení sestavovat trojúhelníky, úsečky, vrcholy.
- Základní primitiva (trojúhleník, úsečka) mohou být součástí složitějších primitive.
- Triangle Strip, Triangle Fan, Line Strip, Triangle Adjacency, Patch, ...

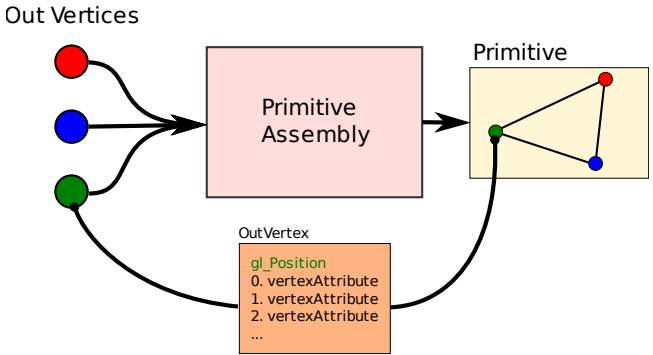

- Těsně před raterizací se zahazují odvrácené trojúhelníky a zbylé se ořezávají pohledovým frustem.

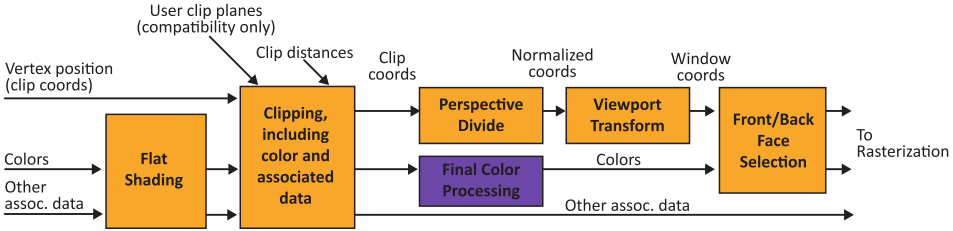

- Culling se stará o zahazování odvrácených trojúhelníků.
- Odvrácenost je rozhodnuta na základě pořadí vrcholů.
- Je možné nastavit, jestli je trojúhelník přivrácený nebo odvrácený, pokud jsou vrcholy po nebo proti směru hodinových ručiček.

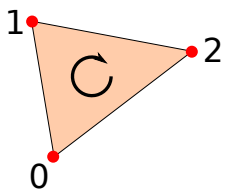

clock wise CW

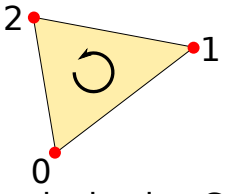

counter clock wise CW

Clipping, near-plane clipping

- Pokud je primitivum jen částečně uvnitř pohledového jehlanu, je potřeba jej oříznout.
- Obvykle stačí oříznout pomocí blízké ořezové roviny (near-plane).
- Pokud vznikne čtyčúhelník, je možné jej nahradit dvěma trojúhelníky.

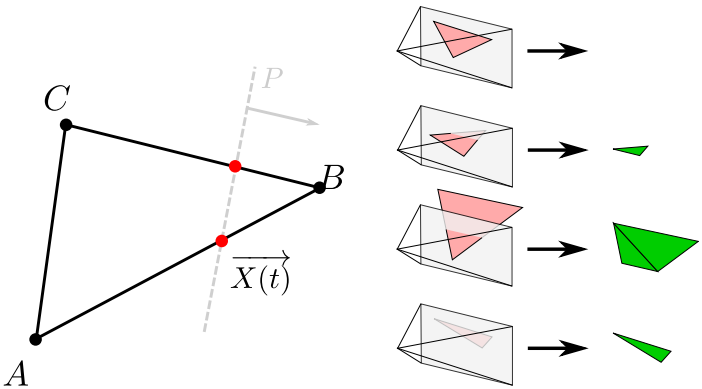

Perspektivní dělení

- Blok perspektivního dělení převádí homogenní souřadnice na kartézské.
- Dělí se pomocí W, ve kterém je uložena hloubka. Tím se zmenšují objekty, které jsou dál od kamera.
- Po perspekvitním dělení všechny vrcholy leží v rozsahu $[-1, +1]$ - normalized device coordinates.

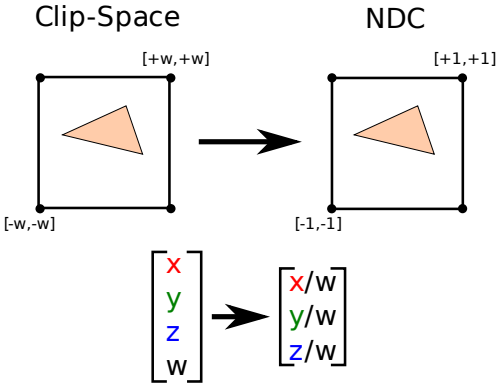

- Blok viewport transformace transformuje normalizované souřadnice na rozlišení plátna.

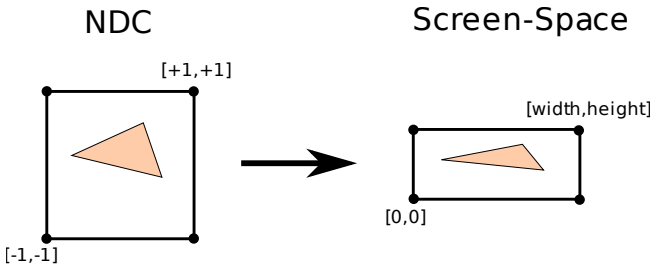

- Tesselace je složena zde 2 programovatelných processorů a hardwarového generátoru primitiv.

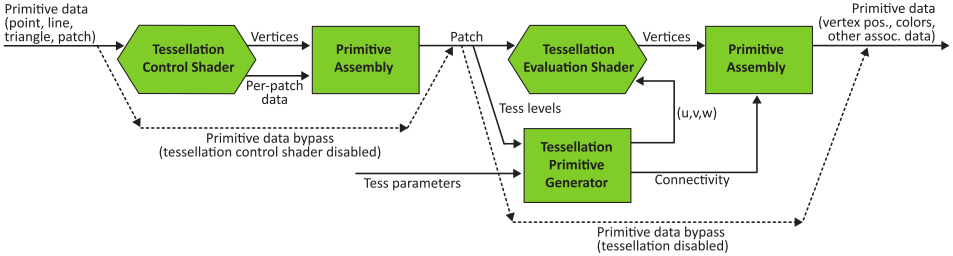

Geometry processor, transform feedback

- Geometry processor transformuje primitiva.
- Transform feedback může primitiva přeposlat zpět do bufferu.

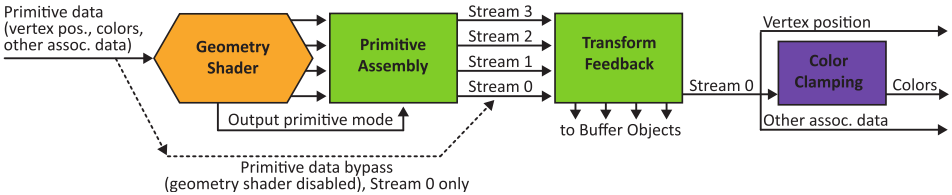

- Rasterizace produkuje fragmenty.
- Fragment je datová struktura, která vznikne na pozici vzorku (sampling point).
- Vzorkovací bod je obvykle uprostřed pixelu.
- Situace je komplikovanější při využití multi-samplingu.
- Pokud leží vzorkovací bod uvnitř trojúhelníku, vznikne fragment pro daný pixel.

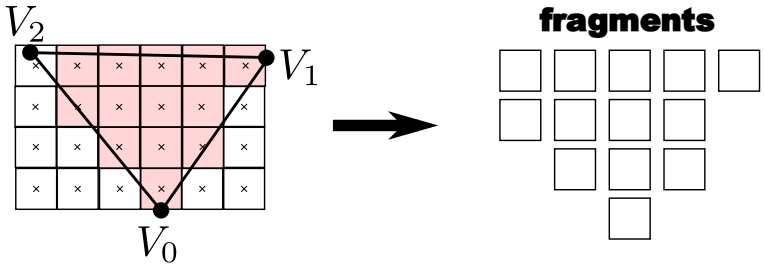

Rasterizace a interpolace

- Vertexy jsou před rasterizací popsány pomocí n-tice atributů
- Rasterizace produkuje fragmenty, pokud jejich střed leží uvnitř primitiva
- Po rasterizaci jsou tyto atributy vloženy do fragmetů pomocí interpolace

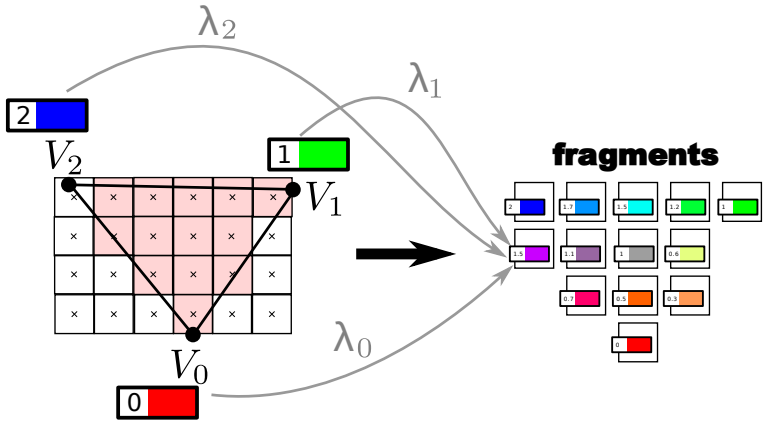

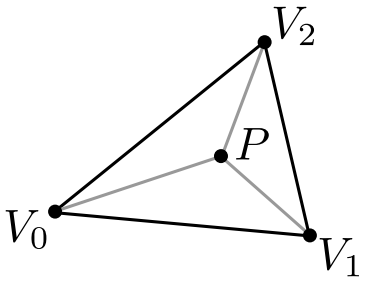

$$P = V_0 \cdot w_0 + V_1 \cdot w_1 + V_2 \cdot w_2$$

$$w_0, w_1, w_2 \in \langle 0, 1 \rangle$$

$$w_0 + w_1 + w_2 = 1$$

Barycentrické koordináty ve 2D

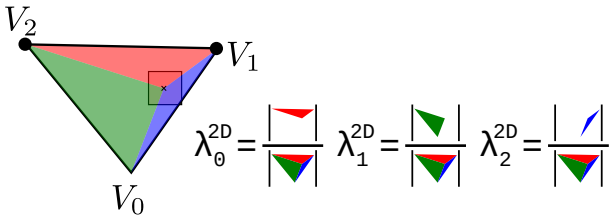

- Vertex atributy se mohou interpolovat v rovině průmětny nebo v prostoru scény
- Aby se mohlo interpolovat v prostoru scény, musí se provést perspektivní korekce (v OpenGL automaticky/lze vypnout)

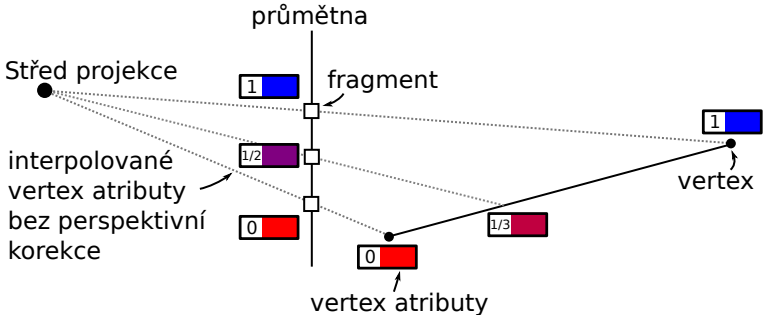

- Ve Fragment Processoru běží fragment shader.
- Fragment Shader je uživatelem specifikovaný program.
- Cílem je transformovat vstupní fragment na výstupní fragment.
- Multiple Render Target.

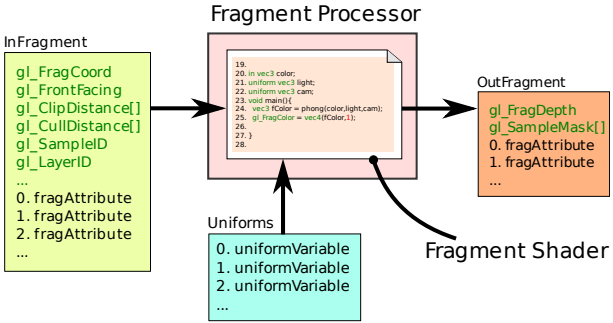

Rastrová část - Brzké testy a operace

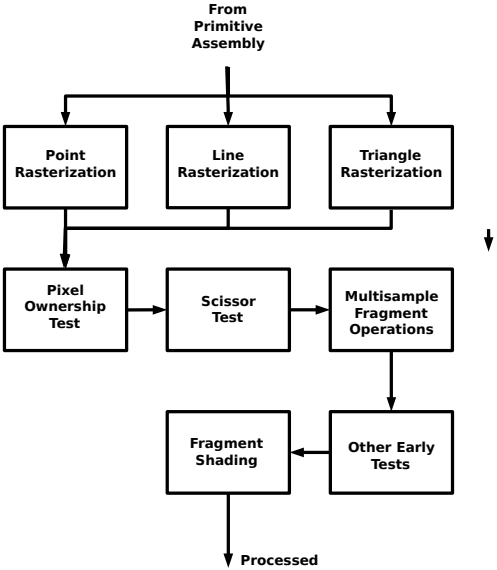

Rastrová část - Pozdní testy a Per fragment operace

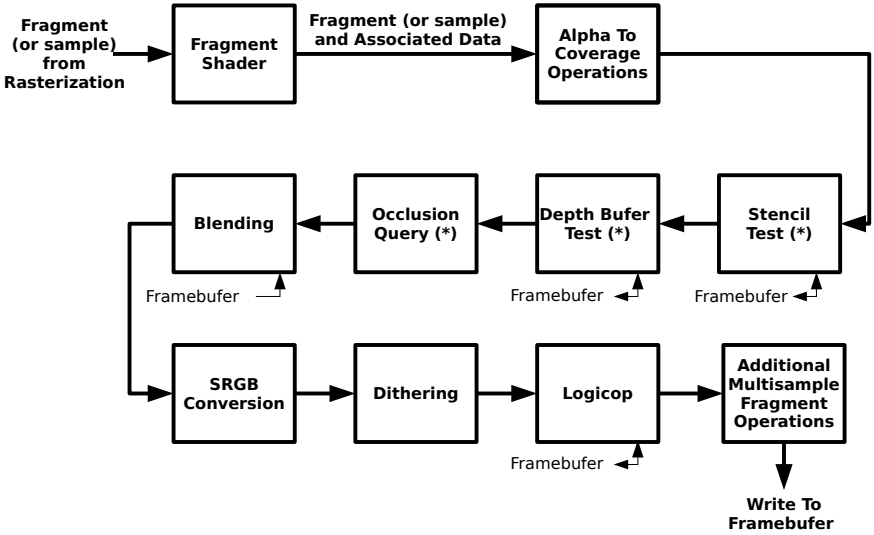

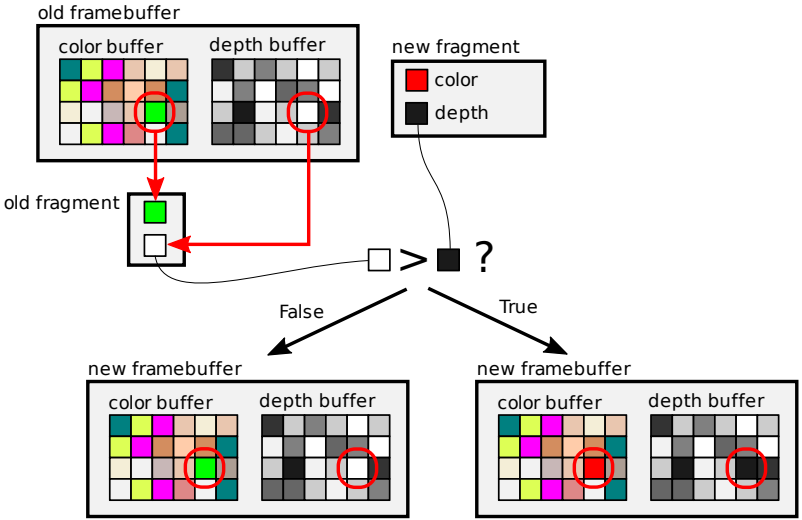
old framebuffer
color buffer
depth buffer
new fragment
color
depth
old fragment
>
?
False
True
new framebuffer
color buffer
depth buffer
new framebuffer
color buffer
depth buffer

OpenGL 4.6 pipeline

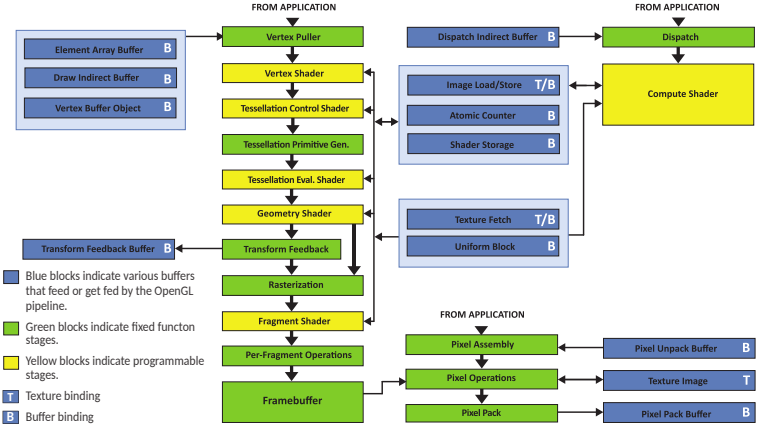

OpenGL

- OpenGL Open Graphics Language (Library)
- OpenGL je API pro 3D grafiku
- Vychází z IrisGL od SGI
- Platformně nezávislé
- Použitelné skoro z každého jazyka
- Slouží pro převod scény popsané primitivy (body, čáry trojúhelníky) na 2D rastr obrazovky.
- V novější verzi (4.3) i pro GPGPU
- Obsahuje vlastní jazyk GLSL pro programování GPU

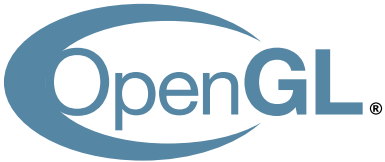

OpenGL - proč používat?

- OpenGL je multiplatformní - Linux, Window, Mac Os X, Android,...
- OpenGL lze použít téměř z každého jazyka - C, C++, Python, Java, Javascript, ...
- OpenGL je zpětně kompatibilní
- OpenGL je nízkoúrovňové
- OpenGL má jednoduché API
- OpenGL je rychlé
- OpenGL je otevřený industriální standard
- WebGL

Verze OpenGL

- OpenGL
  - 1.x - fixní pipeline
  - **2.x** - programovatelná pipeline
  - 3.x - geometry shader, **Deprecation**
  - 4.x - Hardwarová tesselace, dvojitá přesnost
  - 4.3 - Compute shadery
  - 4.5 - Direct State Access
- OpenGL ES
  - Vestavěné systémy, mobily, tablety
  - 1.x - fixní pipeline
  - **2.x** - programovatelná pipeline
  - 3.x - Occlusion queries, 3D textury, transform feedback
- WebGL
  - OpenGL ve webovém prohlížeči
  - **Velmi podobné OpenGL ES**

- OpenGL je architektura klient server
- Aplikace běží na CPU a využívá OpenGL pro přístup k GPU

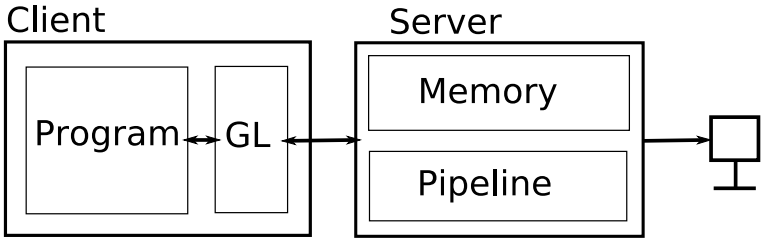

CPU

1. upload data to buffers
2. prepare shaders
3. setup vertex puller
4. setup uniforms
5. execute draw call

GPU

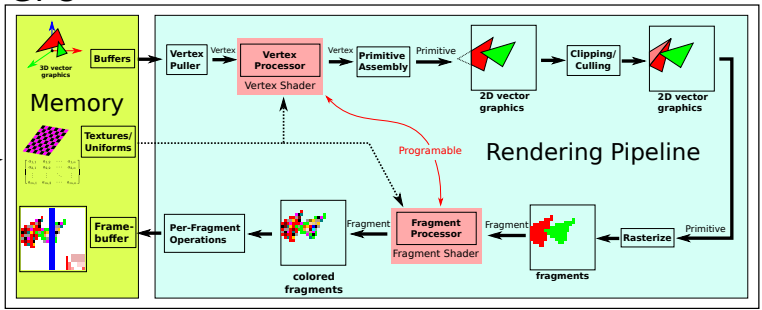

- Jednoduché rozhraní
  - Pouze C funkce
  - Data jsou jen čísla a pole
  - Žádné struct, class
- Stavový stroj
  - Většina příkazů nastavuje stav pipeline
  - Stav se sám nemění
- OpenGL (Rendering) Context
  - Hlavní objekt OGL
  - Mimo OpenGL (WGL/GLX)
  - Zapouzdřuje data, stav, napojení na výstup

glName*NT*(...)

- N - počet parametrů
- T - typ parametrů

b	8b integer	signed char	GLbyte
s	16b integer	short	GLshort
i	32b integer	long	GLint,GLsizei
f	32b float	float	GLfloat,GLclampf
d	64b float	double	GLdouble,GLclampd
ub	8b unsigned	unsigned char	GLubyte,GLboolean
us	16b unsigned	unsigned short	GLushort
ui	32b unsigned	unsigned long	GLuint,GLenum,GLbitfield
*v	Ukazatel a *		

GLvoid

glUniform2f(GLuint,GLfloat,GLfloat); GLvoid glUniform2fv(GLuint,GLfloat*);

OpenGL příkazy lze rozdělit do několika skupin

- **Příkazy pro správu OpenGL objektů (10 hlavních OpenGL objektů)**
- **Exekuční příkazy (kreslící a výpočetní příkazy)**
- **Stavové příkazy (nastavují globální stav OpenGL, příkazy pro zjištění stavu)**
- Debugovací příkazy
- Operace s framebufferem
- Příkazy pro synchronizaci (glFinish)
- Utilitní příkazy

OpenGL Objekty

GLvoid glGen*Objects*(GLsizei n,GLuint * objects);
GLvoid glDelete*Objects*(GLsizei n,const GLuint * objects);

- Jméno objektu - GLuint, všechny objekty jsou v API reprezentovány integerem
- 0 rezervována pro prázdný objekt

Objekty:

- **Program**
- **Shader**
- **Buffer**
- **Vertex Array Object**
- Texture
- Framebuffer
- Renderbuffer
- Sampler
- Asynchronous Query
- ProgramPipeline

Způsob využití OpenGL pro kreslení

- Pro vykreslení grafiky pomocí OpenGL je potřeba inicializovat několik objektů
- Shader Program(y), Buffer(y), Vertex Array Object(y)
- Inicializace spočívá v kompilaci a likování programů
- Alokaci a kopírování dat na GPU
- Konfigurace stavů OpenGL a konfigurace čtení z GPU paměti
- Spuštění kreslení pomocí vykreslovacích příkazů

Příprava programů a shaderů pro GPU

Dva druhy programovacích jazyků

- OpenGL standard popisuje i jazyk GLSL
- Jazyk GLSL popisuje programy, které běží na GPU
- Programátor 3D grafiky píše aplikaci vždy ve 2 jazycích

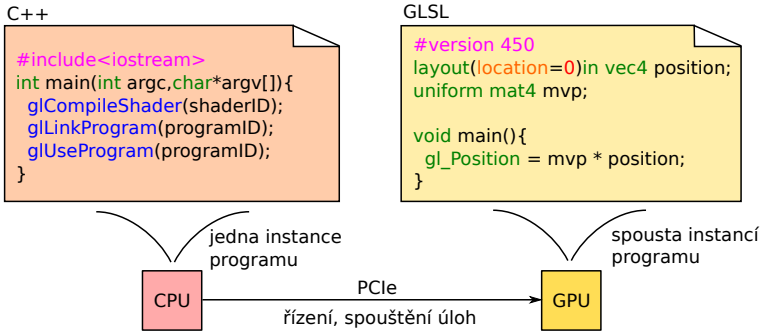

Programy a Shadery

- Program, který běží na GPU se v OpenGL označuje jako Shader Program
- Shader Program je složen z několika částí (stages), které se nazývají Shader
- Existuje 6 typů shaderů: **vertex**, **fragment**, geometry, tesselation control, tesselation evaluation a compute shader.
- Program nemusí obsahovat všechny typy shaderů.
- Jednotlivé shadery lze sdílet mezi vícero programy.
- Shadery se kompilují (za běhu aplikace)
- Programy se linkují (za běhu aplikace)

Validní a často používané kombinace shaderů:

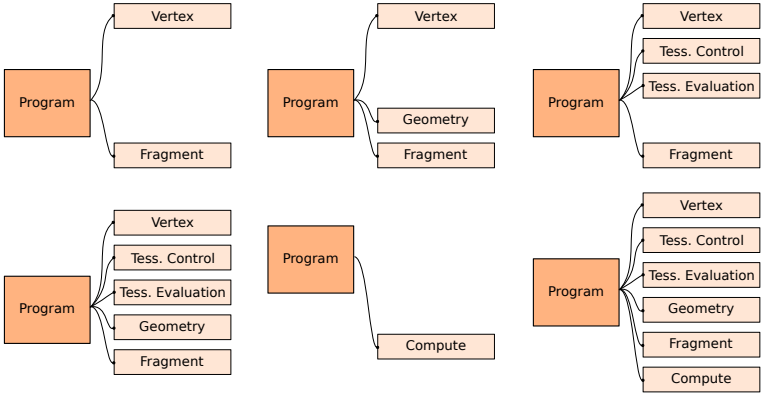

Kompilace shaderů

```
template<typename...ARGS>
GLuint compileShader(GLenum type,ARGS... sources){
  std::vector<std::string>str = {std::string(sources)...};
  std::vector<const GLchar*>ptr;
  for(auto const&x:str)ptr.push_back(x.c_str());

  //reserve shader id
  GLuint id = glCreateShader(type);

  //set shader sources
  glShaderSource(id,(GLsizei)ptr.size(),ptr.data(),nullptr);

  //compile shader
  glCompileShader(id);

  //get compilation log
  GLint bufferLen;
  glGetShaderiv(id,GL_INFO_LOG_LENGTH,&bufferLen);
  if(bufferLen>0){
    char*buffer = new char[bufferLen];
    glGetShaderInfoLog(id,bufferLen,nullptr,buffer);
    std::cerr<<buffer<<std::endl;
    delete[]buffer;
    return 0;
  }
  return id;
}
```

Linkování programů

```
template<typename...ARGS>
GLuint createProgram(ARGS...args){
  //reserver program id
  GLuint id = glCreateProgram();

  //attach all shaders
  auto dummy0 = {(glAttachShader(id,args),0)...};
  (void)dummy0;

  //link program
  glLinkProgram(id);

  //get linking log
  GLint bufferLen;
  glGetProgramiv(id,GL_INFO_LOG_LENGTH,&bufferLen);
  if(bufferLen>0){
    char*buffer = new char[bufferLen];
    glGetProgramInfoLog(id,bufferLen,nullptr,buffer);
    std::cerr<<buffer<<std::endl;
    delete[]buffer;
    glDeleteProgram(id);
    id = 0;
  }
  //mark shaders for deletion
  auto dummy1 = {(glDeleteShader(args),0)...};
  (void)dummy1;
  return id;
```

Ukázka volání/sestavení programu

```
#include<iostream>
#include<fstream>

std::string loadFile(std::string fileName){
  std::ifstream f(fileName.c_str());
  if(!f.is_open()){
    std::cerr<<"file: "<<fileName<<" does not exist!"<<std::endl;
    return 0;
  }
  std::string str((std::istreambuf_iterator<char>(f)),
      std::istreambuf_iterator<char>());
  f.close();
  return str;
}

int main(int32_t argc,char*argv[]){
  ...
  GLuint program = createProgram(
      compileShader(GL_VERTEX_SHADER  ,loadFile("flag.vp")),
      compileShader(GL_FRAGMENT_SHADER,loadFile("usefulFunctions.fp"),
                                       loadFile("flag.fp")));
  ...
}
```

- GLSL - OpenGL Shading Language
- Slouží pro popis programů, které běží na GPU
- Je odvozený od C
- Neobsahuje rekurzi, třídy, výjimky, std knihovny
- Obsahuje vektorové a maticové typy, vestavěné funkce, vestavěné proměnné, synchronizační funkce, typové kvalifikátory, rozšířené adresování vektorů
- Každý shader musí obsahovat main funkci
- Každá main funkce je vykonávána v mnoha instancích v dané části pipeline
- Některé části pipeline mají speciální nastavení

Jazyk GLSL - příklad typy

```
#version 450

void main(){
  //32 bit integer
  int a;
  //32 bit unsigned integer
  uint b;
  //32 bit float
  float c;
  //vector of 4 ints
  ivec4 d;
  //vector of 3 floats
  vec3 e = vec3(1,2,3);
  //matrix 3x3 of floats
  mat3 m;
  //zeroth element of e
  e[0] == e.x == e.r;
  //swizzling
  vec2 f = e.xy; // (1,2)
  f = e.zz; // (3,3)
  //matrix vector multiplication
  e = m*e;
  //constructing ivec4 from vec3 and scalar
  d = ivec4(c,4);
  d = ivec4(c.xx,c.yy);
}
```

Jazyk GLSL - vestavěné funkce

```
abs acos acosh asin asinh atan atanh ceil cos cosh degrees exp exp2 floor fract inversesqrt
log log2 max min mod modf pow radians round roundEven sign sin sinh sqrt tan tanh trunc
clamp cross distance dot floatBitsToInt floatBitsToUint fma frexp intBitsToFloat isinf
isnan ldexp length mix normalize smoothstep step

packDouble2x32 packSnorm4x8 packUnorm2x16 packSnorm2x16
packUnorm4x8 uintBitsToFloat unpackDouble2x32 unpackSnorm4x8 unpackUnorm2x16
unpackSnorm2x16 unpackUnorm4x8 packHalf2x16 unpackHalf2x16

all any bitCount bitfieldExtract bitfieldInsert bitfieldReverse determinant equal
faceforward findLSB findMSB greaterThan greaterThanEqual imulExtended inverse lessThan
lessThanEqual matrixCompMult not notEqual outerProduct reflect refract transpose uaddCarry
umulExtended usubBorrow

textureSize textureQueryLod texture textureProj textureLod
textureOffset texelFetch texelFetchOffset textureProjOffset textureLodOffset textureProjLod
textureProjLodOffset textureGrad textureGradOffset textureProjGrad textureProjGradOffset
textureGather textureGatherOffset textureGatherOffsets textureQueryLevels

dFdx dFdy fwidth
interpolateAtCentroid interpolateAtOffset interpolateAtSample

noise1 noise2 noise3 noise4

EmitStreamVertex EndStreamPrimitive EmitVertex EndPrimitive

barrier memoryBarrier
memoryBarrierAtomicCounter memoryBarrierBuffer memoryBarrierImage memoryBarrierShared
groupMemoryBarrier
imageSize

atomicAdd atomicMin atomicMax atomicAnd atomicOr atomicXor atomicExchange atomicCompSwap

imageSize imageLoad imageStore imageAtomicAdd imageAtomicMin imageAtomicMax
imageAtomicAnd imageAtomicOr imageAtomicXor imageAtomicExchange imageAtomicCompSwap
```

Jazyk GLSL - kvalifikátory proměnných

```
#version 450

//promenna a je plnena predchazejici shader stage nebo
//z bufferu GL_ARRAY_BUFFER
//read only
in vec4 a;

//hodnota b bude viditelna v dalsi shader stage nebo
//ve framebufferu
//write only
out vec4 b;

//hodnoty promennych a,b se meni s kazdou invokaci shaderu

//promenna m je ulozena v konstantni pameti, lze ji vycist
//ve vsech shader stage
//read only
uniform mat4 m;

//hodnota m je nemenna pro vsechny invokace shaderu

//promenna d je typu textury (obrazek), je to opaque type, ktery
//lze cist jen pomoci specialnich funkci
//read only
uniform sampler2D d;

//promenna e je lokalni, je ulozena v registru, kazda
//invokace shaderu ma svoji vlastni
vec4 e = vec4(0,1,2,3);

void main(){
  b = e + m * texture(d,a.xy);
}
```

Vertex Shader obsahuje několik důležitých vestavěných proměnných

```
#version 450

void main(){
  //vystupni promenna, sem se zapisuje pozice vrcholu
  //po perspektivni projekci
  vec4 gl_Position;

  //cislo vrcholu
  in int gl_VertexID;
  //cislo instsance
  in int gl_InstanceID;
  //cislo draw callu
  in int gl_DrawID;
  //velikost primitiva typu bod
  out float gl_PointSize;
  out float gl_ClipDistance[];
  out float gl_CullDistance[];
}
```

Jazyk GLSL - důležité vestavěné proměnné

Fragment Shader obsahuje několik důležitých vestavěných proměnných. Výstup fragment shaderu si specifikuje programátor pomocí vlastní výstupní proměnné.

```
#version 450

//vlastni vystup, namapuje se na 0. barevny framebuffer
layout(location=0)out vec4 fColor;

void main(){
  //coordinaty fragmentu ve viewportu
  in vec4 gl_FragCoord;

  //vznikl fragment z privracene strany primitiva
  in bool gl_FrontFacing;

  //pro modifikaci hloubky fragmentu
  //pri zapisu vypina brzky depth test
  out float gl_FragDepth;

  in float gl_ClipDistance[];
  in float gl_CullDistance[];
  in int gl_PrimitiveID;

}
```

Příprava bufferů

Buffery

- Buffer je objekt zastřešující lineární paměť na GPU
- Může obsahovat jakákoliv data
- Nejčastěji se používá pro uložení vrcholů geometrie (a jejich vlastností), indexů na vrcholy a materiálů
- Buffer lze připojit na několik přípojných míst OpenGL pipeline (binding points)
- Binding point udává sémantiku bufferu
- Pro vrcholy se používá GL_ARRAY_BUFFER, buffer se pak nazývá Vertex Buffer Object (VBO)
- Pro indexy se používá GL_ELEMENT_ARRAY_BUFFER, Element Buffer Object (EBO)
- Pro obecná data se používá GL_SHADER_STORAGE_BUFFER

OpenGL 4.6 pipeline

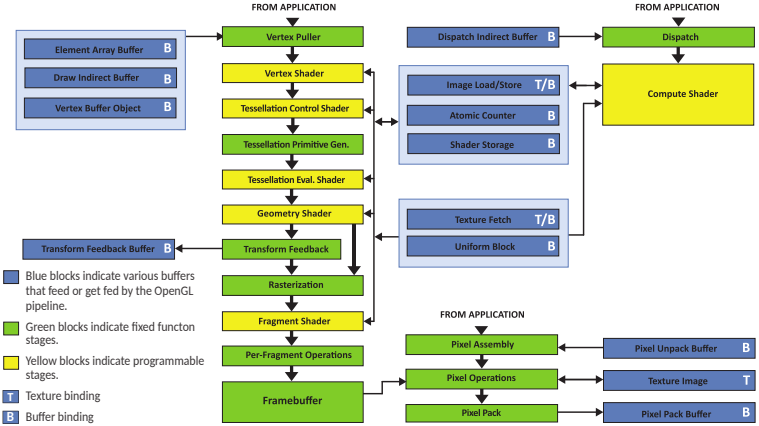

Vytvoření buffer, nahrání dat

Vytvoření bufferu.

```
float data[]={1,2};//data, ktera budeme vkladat do bufferu
GLuint vbo;//identifikator VBO
glCreateBuffers(1,&vbo);
//alokujeme buffer a nahrajeme do nej data
glNamedBufferData(vbo,sizeof(data),data,GL_STATIC_DRAW);
```

Změna dat ve VBO.

```
float*ptr;//ukazatel na data
ptr=(float*)glMapNamedBuffer(vbo,GL_READ_WRITE);//namapujeme buffer
ptr[0]=0.5;//nastavime hodnotu prvniho prvku
glUnmapNamedBuffer(vbo);//odmapujeme buffer, komitujeme zmeny do GPU
```

Nebo pomoci glNamedBufferSubData.

```
glNamedBufferSubData(vbo,
  sizeof(float),//nahrajeme nova s offsetem jeden float
  sizeof(float),//nahrajeme jen jeden float
  data);//data
```

Nabindování bufferu.

```
glBindBuffer(GL_ARRAY_BUFFER,vbo);
```

Konfigurace Vertex Pulleru/Vertex Array Object

Vertex Array Object

- Vertex Array Object (VAO) obsahuje konfiguraci Vertex Puller jednoty.
- Vertex Puller čte data z bufferů a plní je do vstupních proměnných v prvním shaderu (vertex shader)
- VAO obsahuje nastavení propojení Shader Programu a Bufferů
- V novějších verzích OpenGL je povinný
- Obsahuje sadu nastavení pro každý Vertex Attribut a nastavení pro indexový buffer
- Jeden Vertex Attribut je napojen na jednu vstupní proměnnou ve Vertex Shaderu
- Mezi nastavení Vertex Attributu patří: číslo bufferu, velikost a typ datové položky, prokládání (stride), offset

Příklad - ilustrace 0. invokace vertex shaderu

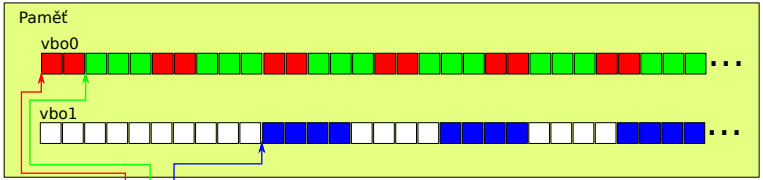

Vertex Shader - 0. invokace

```
#version 450
layout(location=0)in vec2 coord;
layout(location=1)in vec3 normal;
layout(location=2)in vec4 position;

uniform mat4 mvp;

void main(){
  ...
  gl_Position = mvp * position;
}
```

Příklad - ilustrace 1. invokace vertex shaderu

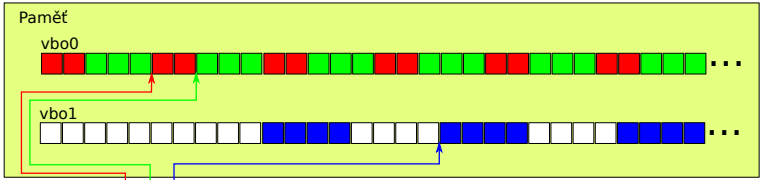

Vertex Shader - 1. invokace

```
#version 450
layout(location=0)in vec2 coord;
layout(location=1)in vec3 normal;
layout(location=2)in vec4 position;

uniform mat4 mvp;

void main(){
  ...
  gl_Position = mvp * position;
}
```

VAO - příklad

```
GLuint vao;
glCreateVertexArrays(1,&vao);//vygenerovani jmena VAO
//nyni nastavime buffery a atributy

glVertexArrayAttribBinding(vao,0,0);
glEnableVertexArrayAttrib(vao,0);
glVertexArrayAttribFormat(vao,
  0,//cislo vertex attributu
  2,//pocet polozek pro cteni (vec2)
  GL_FLOAT,//typ polozek
  GL_FALSE,//normalizace
  0);//relativni offset
glVertexArrayVertexBuffer(vao,0,
  vbo,
  sizeof(float)*5,//stride
  (GLvoid*)(sizeof(float)*0));//offset

glVertexArrayAttribBinding(vao,1,1);
glEnableVertexArrayAttrib(vao,1);
glVertexArrayAttribFormat(vao,1,3,GL_FLOAT,GL_FALSE,0);
glVertexArrayVertexBuffer(vao,1,vbo,sizeof(float)*5,
  (GLvoid*)(sizeof(float)*2));

glVertexArrayAttribBinding(vao,2,2);
glEnableVertexArrayAttrib(2);
glVertexArrayAttribFormat(2,4,GL_FLOAT,GL_FALSE,0);
glVertexArrayVertexBuffer(vao,2,vbo,sizeof(float)*8,
```

```
glVertexArrayAttribBinding(GLuint vao,GLuint attribIndex,GLuint bindingIndex);
glVertexArrayAttribFormat(GLunit attribIndex,GLint size,GLenum type, GLboolean normalized, GLuint relativeoffset);
```

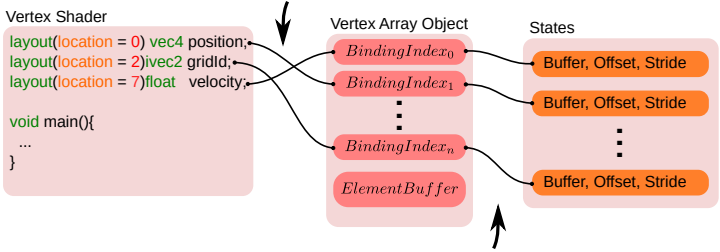


```
glBindVertexBuffer(GLuint bindingIndex, GLuint buffer, GLintptr offset, GLsizei stride);
...
```

Kreslení a uniformní proměnné

Uniformní proměnné

- Uniformní proměnné jsou uloženy v konstantní paměti
- Narozdíl od vertex atributů se v průběhu kreslení nemění
- Každá invokace shaderu adresuje stejnou hodnotu
- Uniformní proměnné lze využít ve všech shader stage
- Uniformní proměnné jsou vhodné například pro uložení matic, barvy, světla
- Stejně jako objekty v OpenGL zastupuje integerová hodnota, tak i každá uniformní proměnná má svoje integerové jméno
- Toto jméno lze získat z Shader Programu pomocí specializovaných funkcí

Způsob využívání uniformních proměnných

1. Vytvoření Shader Programu
2. Získání integerového jména pomocí jména proměnné v shaderu
3. Aktivování Shader Programu
4. Nahrání dat pomocí vhodné OpenGL funkce

```
GLuint program = 0;
GLint  colorUniform = -1;
void init(){
  //sestaveni programu
  program = createProgram(
      compileShader(GL_VERTEX_SHADER  ,loadFile("flag.vp")),
      compileShader(GL_FRAGMENT_SHADER,loadFile("flag.fp")));
  //ziskani integeroveho jmena z promenne "color" v shaderu
  colorUniform = glGetUniformLocation(program,"color");
}
```

```
#verion 450

layout(location=0)out vec4 fColor;
uniform vec3 color;//uniformni promenna
void main(){
  fColor = vec4(color,1);
}
```

Vykreslení dat

1. Aktivování programu
2. Nastavení uniformních proměnných
3. Aktivování Vertex Array Objectu
4. Zavolání vykreslovacího příkazu

```
void draw(){
  //vymazani barevneho framebuffer
  glClear(GL_COLOR_BUFFER_BIT);

  //aktivovani program
  glUseProgram(program);

  //nastaveni uniformni promenne
  glProgramUniform3fv(program,colorUniform,1,0,0);

  //aktivovani vao
  glBindVertexArray(vao);

  glDrawArrays(//vykresleni
    GL_TRIANGLES,//typ primitiva
    0,//prvni Vertex
    3);//pocet Vertexu pro vykresleni 3 -> 1 trojuhelnik

  //deaktivovani vao
  glBindVertexArray(0);
```

Per fragment operace

Per fragment operace

- Po fragment shaderu jsou na fragmenty aplikovány Per fragment operace
- Nejzákladnější operací je řešení viditelnosti pomocí depth testu
- Viditelnost se v OpenGL řeší pomocí Depth Buffer (paměť hloubky)
- Další testy jsou Stencil test a Scissor test
- Mezi jiné operace patří Blending, který se využívá pro průhledné objekty

Depth Test a Depth Buffer

- Depth test řeší viditelnost pomocí Depth Bufferu a to na úrovni fragmentů
- Různé způsoby nastavení
- Přesnost depth bufferu není nekonečná (většinou 24 bitů)
- Častý problem depth bufferu je jev známý jako depth Fight
- Brzký depth test - depth test může předběhnout vykonávání fragment shaderu
- Brzký depth test se provádí tehdy, pokud se ve fragment shaderu nemodifikuje hloubka fragmetu
- Brzký depth test může značně urychlit kreslení

```
glEnable(GL_DEPTH_TEST);//zapneme depth test - nastavi se stav pipeline
glDepthFunc(GL_LEQUAL);//fragment s mensi nebo stejnou hloubkou projde
glDepthMask(GL_TRUE);//maskovani zapisu do depth bufferu
```

Bleding - průhledné objekty

- Blending umožňuje kombinovat novou barvu s již zapsanou barvou ve framebufferu
- Blending je řízen pomocí blendovací operace, source a destination faktorů
- Blendovací operace jsou sčítání, odčítání, min, max, ...
- Source faktor se aplikuje na barvu fragmentu
- Destination faktor se aplikuje na barvu již uloženou ve framebufferu
- Nutnost kreslit ve správném pořadí

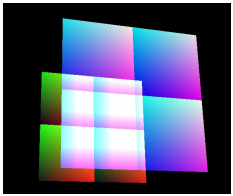

```
glEnable(GL_BLEND);//zapneme blending
glBlendEquation(GL_FUNC_ADD);//barvy se budou scitat
glBlendFunc(GL_SRC_ALPHA,GL_ONE_MINUS_SRC_ALPHA);//nastavime zpusob michani
```

OpenGL kontext, knihovny

SDL - Simple Directmedia Layer

- IO, okna, zvuky, vlákna, ...

GLM - GL mathematics

- Práce s vektory a maticemi

GLEW - OpenGL Extension Wrangler

- OpenGL rozšíření

GLUT - GL Utility Toolkit (IO, okna, ...)
GLEE - GL Easy Extension library
GLAUX - GL Auxiliary Library (IO, okna, ...)
GLFW - (IO, okna, ...)

- glext.h
- void*wglGetProcAddress(const char*name);
- void*glXGetProcAddress(const char*name);
- PFNGL*NECO*PROC glNeco=(PFN...)wglGetProcAddress("glNeco");
- glGetString(GL_EXTENSIONS);
- GL_XYZ_name
- GL_ARB_multisample
- GL_EXT_blend_func_separate
- IBM,NV,ATI,SGIS,...
- GLEE/GLEW

OpenGL kontext

- OpenGL kontext zapouzdřuje věškeré nastavení OpenGL
- Zastřešuje všechny objekty (buffer, programy, textury, ...)
- Po jeho uvolnění, nejsou již data na GPU přístupná
- OpenGL kontext není popsán v OpenGL specifikaci a lze jej vytvořit z externích knihoven
- Kontext má svoji verzi (vertex OpenGL), možnost aktivovat debugging, a různe profily

Vytvoření kontextu - SDL2

```
//vytvoreni okna v SDL2
unsigned version = 450;//context version
unsigned profile = SDL_GL_CONTEXT_PROFILE_CORE;//context profile
unsigned flags   = SDL_GL_CONTEXT_DEBUG_FLAG;//context flags
SDL_Init(SDL_INIT_VIDEO);//init. video
SDL_GL_SetAttribute(SDL_GL_CONTEXT_MAJOR_VERSION, version/100    );
SDL_GL_SetAttribute(SDL_GL_CONTEXT_MINOR_VERSION,(version%100)/10);
SDL_GL_SetAttribute(SDL_GL_CONTEXT_PROFILE_MASK ,profile         );
SDL_GL_SetAttribute(SDL_GL_CONTEXT_FLAGS        ,flags           );

SDL_Window*window = SDL_CreateWindow("sdl2",0,0,1024,768,
  SDL_WINDOW_OPENGL|SDL_WINDOW_SHOWN);
SDL_GLContext context = SDL_GL_CreateContext(window);//create context

glewExperimental=GL_TRUE;
glewInit();//initialisation of gl* functions
```